

國立清華大學資訊工程系 108 學年度上學期專題報告

專題名稱	Medical image denoising with machine learning				
參加競賽或計畫	<input type="checkbox"/> 參加對外競賽		<input type="checkbox"/> 參與其他計畫		<input checked="" type="checkbox"/> 無參加對外競賽或任何計畫
學號	105062310	105062230	105062333		
姓名	范孜亦	簡子昀	李俊廷		

摘要

由於醫學影像會因為病人生理動作、設備情況等影響，導致產出的圖像有雜訊，增加醫師判斷上的難度，因此本文欲透過深度學習的概念，探討如何能有效去除電腦斷層掃描圖(CT)以及核磁共振成像(MRI)的雜訊。使用的方法為先圈選好少量雜訊供卷積神經網路(CNN)學習，再藉由 CNN 的能力替我們提取出更多雜訊，將這些雜訊加到原圖上即可形成一張較乾淨的圖和一張較多雜訊的 Paired Data，運用這組 Paired Data 當作輸入資料，導入 Autoencoder 中進行雜訊去除，經過幾次迭代的雜訊去除後，最後獲得一張乾淨的影像。

中華民國 108 年 11 月

目錄

- 一、專題研究動機與目的
- 二、現有相關研究概況及比較
- 三、設計原理、研究方法與步驟
- 四、系統實現與實驗
- 五、專題重要貢獻
- 六、團隊合作方式
- 七、效能評估與成果
- 八、結論

一、專題研究動機與目的

在過去醫生診治病人時，除了觸診就只能透過開刀來了解病人體內的情況，而醫學影像的出現讓醫生多了一種選擇，可以透過非入侵的方法取得病人體內器官的圖像，竟而獲得更精準的判斷。然而因為輻射對人體有害不可以使用過量，且病人在接受掃描時，多少會有生理上的活動，例如心臟跳動或是呼吸運動等等，故使醫學影像產生雜訊影響判斷，所以我們以常見的兩種醫學影像：CT 以及 MRI 當作我們主要的實驗對象，透過深度學習的方法，將圖片中的雜訊找出並去除，重建出較好品質的圖像，幫助醫學人員進行病症分析與判斷，提升醫療品質。

二、相關研究概況

利用深度學習的方法來對醫學影像去雜訊的研究相當多，相對於非學習型演算法的模型，例如 BM3D 和 Deep image Prior (DIP)，對存在於訓練集中的雜訊去除表現得比較好，然而面對多樣的雜訊時，深度學習的方法就沒有非學習型演算法來得好，但本篇將局限於深度學習方法的討論。

Chen *et al.*(2017)運用低輻射劑量的 CT 圖來訓練 CNN，並重建出正常輻射劑量的 CT 圖，Wolterink *et al.*(2017)則是以 CNN 搭配 GNN 來達到去雜訊的效果，而 Yang *et al.*(2018)運用 Wasserstein 距離和感知 loss 找出輸入和輸出圖片間的關聯，以上這些深度學習的方法都需要有 Paired Data (同一個組織的一張較乾淨的圖與一張雜訊較多的圖)來當作訓練資料，藉此學習到雜訊的樣貌，然而 Paired Data 取得不易，故大家常常透過人工模擬的方式來產生雜訊，但產出的終究非真正的雜訊，讓電腦以此學習之後，反而會導致判斷錯誤，所以 You *et al.*(2018)使用 cycleGAN(CCADN)，藉由學習低輻射劑量影像和正常輻射劑量影像來找到雜訊，雖然不強求一定要是同一組照片，但仍然無法找到大量的正常輻射劑量影像來進行訓練，且這些方法通常都需要將資料進行預處理，然而產生雜訊的情況複雜，每個病人的年紀體型、掃描機器的情況或是設定不同都會導致結果的差異，所以當這些模型遇到與自己訓練的資料差不多條件的影像時可以有良好的表現，若遇到不相仿的影像時，表現就無法那麼突出。

Yujen Chen, Yujung Chang, Shaocheng Wen 利用從自身提取雜訊再合成的方法，來解決找不相仿的影像的問題。他們所撰寫的”One-Shot” Medical Image Artifact Reduction Through Attentive Generative Network with Internal Data Sythesis and Adversarial Training 所提出的方法是將圖片切成小塊，運用 CNN 將這些小圖區分成有雜、乾淨的結構以及無法區分三種類別，再從中提取雜訊進行合成，組成多個 Paired Data，以 GAN 進行訓練與去雜訊。而另一篇他們撰寫的 Zero-Shot Medical Image Artifact Reduction 則是以平均值與標準差篩選出具雜訊的區塊，再提取雜訊進行合成，最後利用深度較淺的網路，以迭代的方式進行去雜訊，節省時間成本。

於是我們結合兩篇論文的方法，選用 One-Shot 前半部在提取雜訊的手法，期望能透過 CNN 對影像辨識的優異能力，從每張圖片中選出屬於自己的雜訊，即可與原影像產生 Paired Data，有效解決上述人工模擬的誤差，以及找不到同組影像的問題。而在去雜訊的部分，我們選用 Zero-Shot 後半部的方式，運用 Autoencoder 對圖像進行迭代重建的方式，達到消除雜訊的效果，由於 Autoencoder 的架構簡單，大幅減少了神經網路運行的時間，更有利於實際上的應用。

三、設計原理、方法與步驟

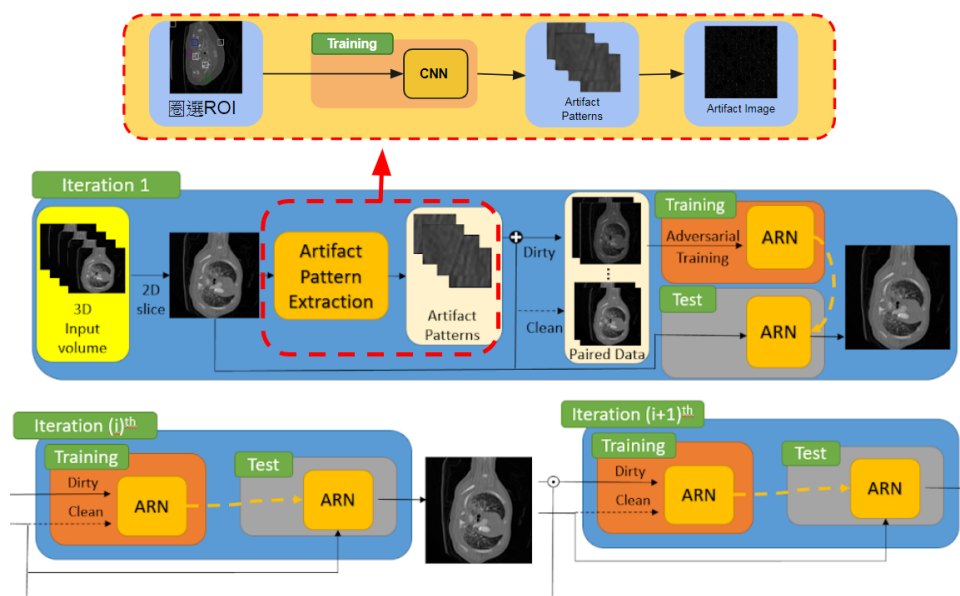


圖 1

3.1 概觀

醫學影像中的雜訊通常只會出現在區域，而不是均勻佈滿整張影像，因此我們可以從影像中區分出具雜訊以及不具雜訊的區塊，從中提取出雜訊，進而藉由將原圖合成上雜訊的方式製作出 Clean-Dirty Paired Data，訓練模型達成去雜訊的工作。

我們設計出的方法架構如圖 1，主要分成提取雜訊與合成，以及迭代去雜訊兩個步驟。我們從 3D 的影像中提取 2D 的 Slice 作為 Input，在第一次迭代時，我們訓練 CNN 網路從原圖中區分出具雜訊的區塊，並從中提取雜訊合成至原圖上，與原圖組合成一對 Clean-Dirty 的 Paired Data，作為去雜訊網路（Artifact Reduction Network，ARN）的訓練資料。

每次訓練完 ARN 後，將組合中的 Clean 影像作為 Input 進行去雜訊，再將去雜訊的結果影像與 Input 影像進行再處理以及合成，成為新的 Clean-Dirty 組合，成為下一次去雜訊迭代的訓練資料。藉由迭代循序去除雜訊，得到越來越乾淨的成果，總共會歷經四次的迭代，完成去雜訊工作。

3.2 雜訊提取以及訓練資料合成

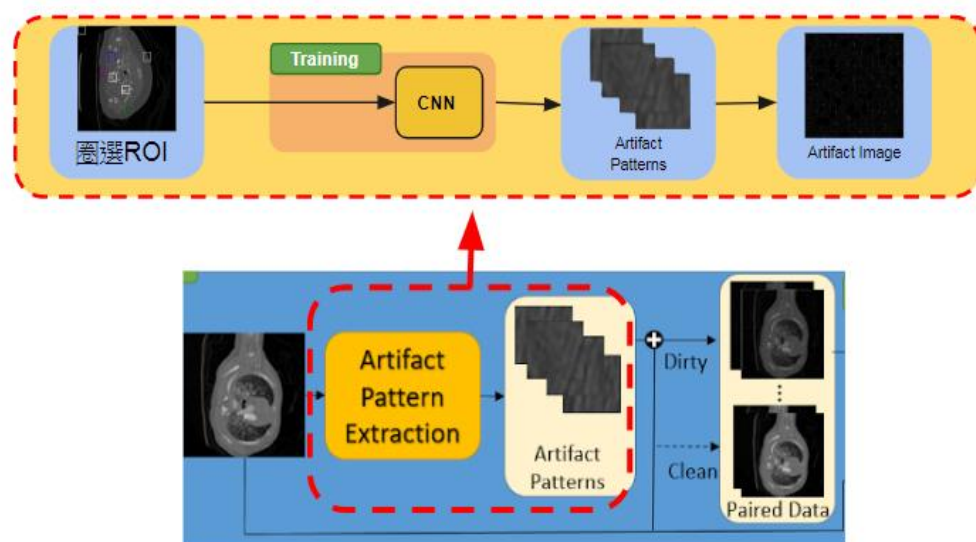


圖 2

在這個部分，我們使用 CNN 從原圖中分類出雜訊區塊，並且提取雜訊與原圖合成。如 3.1 節中所述，醫學影像中的雜訊通常具有區域性，因

此我們可以區分出具雜訊以及不具雜訊的區塊，在影像中圈選雜訊以及非雜訊兩種 ROI（大小：40x40）數張，透過旋轉、映射等方式增加數量，作為訓練 CNN 分類器的訓練集。接著以 Sliding Window 的方式將影像切成 40x40 大小的圖片，輸入 CNN 分類器中分類，篩去包含結構特徵的區塊，再從剩餘的雜訊區塊中減去整塊區塊平均值提取出雜訊。最後，我們將提取出的雜訊隨機組合出一張與影像大小相同的雜訊圖（如圖 3 左），並將其取倍數合成上影像，生成一張雜訊更加嚴重的影像（如圖 3 右），與原影像組成一對 Clean-Dirty Pair Data，作為下一階段 ARN 的訓練資料。




圖 3

3.3 迭代去雜訊




圖 4

一次完整的去雜訊需要經過四次的迭代，每一次迭代的訓練集來源都是來自上一次迭代所得的結果（第一次迭代除外），且每一次迭代也都會

重新訓練一次 ARN 網路。我們設計了結構簡單的 Autoencoder 作為 ARN 來去除雜訊並且保留影像結構，而結構簡單、深度較淺的網路結構只需要少量的 Epoch 去收斂，可以降低迭代訓練的時間成本。

從上一步驟中取得 Clean-Dirty 組合進行第一次迭代訓練，並將其中的 Clean 影像作為 Input 輸入訓練完的 ARN 進行去雜訊，為了將結構保持得更完整清晰，我們將去雜訊完的影像與 Input 相加取平均作為 Output，讓每次去雜訊程度不要太高，提高結構的完整性。

接著將 Input 與 Output 相減，找出兩者相異處進而從中提取雜訊，再使用與 4.2 節步驟相同的提取與合成方法，將影像減去平均值提取出雜訊，合成到 Output 上成為 Dirty，讓其與原 Output 成為下一次迭代的 Clean-Dirty Paired Data，做更進一步的去雜訊，而第四次迭代 ARN 去雜訊完的影像便是整個去雜訊工作完成的成果圖。

四、系統實現與實驗

4.1 dataset

我們的 CT 影像資料集是來自 24 個病患的 48 張 3D 心臟 CT 影像，而 3D 影像是由 256 張大小為 512x512 的 11,616 灰階 2D 影像組合而成，使用輻射劑量分為低輻射劑量與正常輻射劑量兩種，低輻射劑量是使用 80 kVp/55 mAs，正常輻射劑量則是 100 kVp/651 mAs。MRI 則是使用 3T 系統，使用的成像參數有視野：230 mm×230 mm；體素：2 mm×2 mm×8 mm；重複時間：(3.0-3.2) ms；回聲時間：(1.5-1.6) ms；靈敏度系數：2；最小弛緩時間：105 ms；翻轉角度：45 度。

我們的放射科醫生對所有 CT 影像在結構保存和雜訊等級上進行了定性評估。由於缺乏 Ground Truth，對於影像我們選擇與放射科醫生感興趣區域相似的區域。該區域中像素的標準差(雜訊等級)應盡可能的降低，而在減少雜訊後的平均值(物質信息)差異不應太大，以免造成信息丟失。而 MRI 則是使用 SNR 評分規則，將平均值(物質信息)除以標準差(雜訊等級)。

4.2 系統設置與細節

我們使用 Python3 TensorFlow 以及 NVIDIA GeForce GTX 1080 Ti GPU 實作實驗，建立、訓練以及測試模型，並且使用 Xavier 初始化 Kernel。

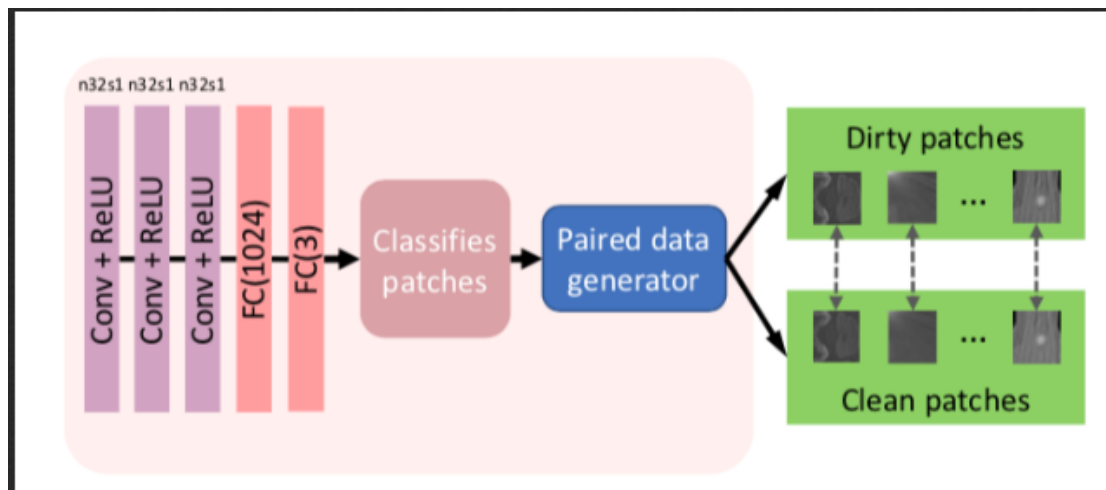


圖 5

4.3 CNN 設置

我們在第一步驟（雜訊提取以及訓練資料合成）架構了只有 5 層的簡單 CNN 作為分類器，用來分類出影像的雜訊區塊，圖 5 為它的架構圖，前 3 層為卷積+ReLU，最後兩層是全連接層（其中 1 層為 Drop Out 層），使用 Softmax 交叉熵作為 Loss Function，並以梯度下降進行最佳化。在訓練時，我們將 Learning Rate 設為 0.0005，Drop Out 層的 Keep Rate 設為 0.5，以 40 批次進行 2000 次 Epoch；而測試時則是將 Keep Rate 設為 1。在分類完後，我們再針對分類器判斷出的具雜訊區塊，以區塊的最大值與最小值做更嚴密的篩選，目的是篩去包含結構特徵的區塊，其中最大值不可以超過 0.34，最小值不可以低於 0.165。

4.4 Autoencoder 設置




圖 6

在迭代去雜訊步驟中，我們設計了結構簡單的 Autoencoder 作為 ARN 來去除雜訊並且保留影像結構，圖 6 為它的架構圖。Autoencoder 總共有 11 層，其中以 Skip Connection 的方式連接 Encoder 層與 Decoder 層（第 2 層到第 10 層，第 4 層到第 8 層），使得 Decoder 層可以從 Encoder 層中取得更多資訊。我們將 Learning Rate 設為 0.005，使用均方差做為 Loss Function 來保持結構訊息，並以 Adam 進行最佳化。

五、專題重要貢獻


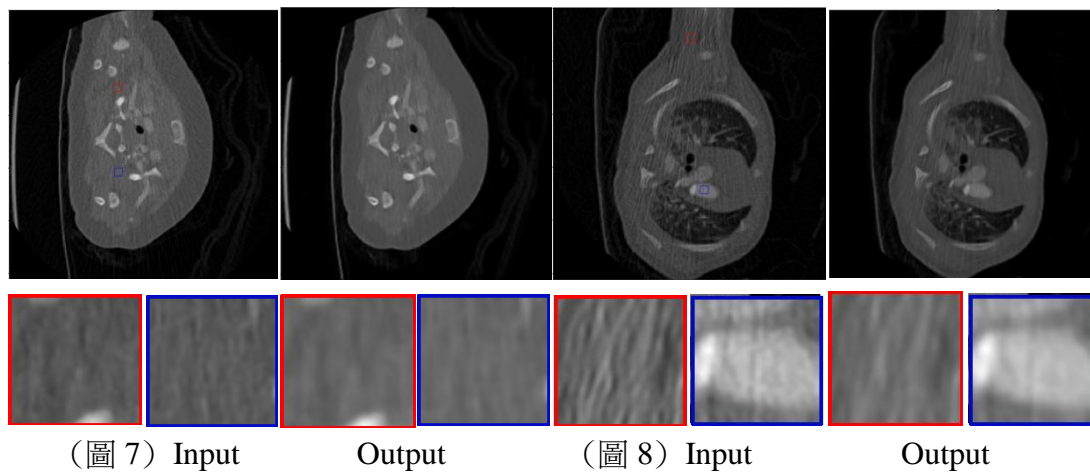
我們以 CT 及 MRI 當作我們主要的實驗對象，透過深度學習的方法，將圖片中的雜訊找出並去除，保有原始的結構，重建出較好品質的醫療影像，幫助醫學人員進行病症分析與判斷，降低因雜訊導致的誤判，提升醫療品質，並期望未來能夠廣泛應用在醫學界。

六、團隊合作方式


我們團隊共有三名成員，自 2019 年 1 月開始，每週開會一次，主要討論當週各自的進度以及彼此遇到何種困難，在會議中提出並且解決問題，在會議的最後，分配各自下一週所要完成的目標。

七、效能評估成果

7.1 CT



7.2 MRI



我們探討了許多不同的 Case，由圖 7 到 11 可知，我們的 Output 比起 Input 都清晰許多，大部分肉眼可見的雜訊已被我們去除。

接著我們比較 CT 圖中紅框與藍框原始圖片與去雜訊後的 Mean 和 Standard Deviation，及 MRI 圖中紅框與藍框原始圖片與去雜訊後的 Mean 和 SNR，再加上我們參考其他 Paper 上使用的方法進行比較，如下表 1 及表 2。

可以得知我們方法的最大優勢在於 Mean 非常穩定，在去雜訊的過程中將正常結構保持完整，而在標準差上大部分的 Case 比起 CCADN 和 BM3D 效果好一點，雖然 DIP 在標準差的數值表現比較好，但是 DIP 有 Oversmoothed 的問題，也就是原來的結構也會變得模糊，並不是理想的結果。

表 1：CT 影像

		Original	(Ours)	CCADN	BM3D	DIP
(圖 7) Red	Mean	54.1	54.9	68.2	48.8	161.7
	SD	79.5	55.6	65.8	72.4	23.7
(圖 7) Blue	Mean	104.4	101.8	118.5	99.3	214.5
	SD	66.0	36.8	48.9	53.4	6.8
(圖 8) Red	Mean	82.9	93.8	96.8	78.5	169.3
	SD	146.3	102.0	129.3	143.1	19.3
(圖 8) Blue	Mean	790.4	817.5	823.9	786.0	970.3
	SD	89.4	67.1	77.7	84.0	67.3
(圖 9) Red	Mean	58.8	65.3	67.1	52.2	52.4
	SD	104.3	77.5	84.9	75.1	44.4
(圖 9) Blue	Mean	71.8	82.4	77.4	61.5	55.1
	SD	134.3	102.1	104.5	112.9	12.1
(圖 10) Red	Mean	103.7	115.5	68.2	95.6	99.5
	SD	97.4	53.5	90.3	91.2	20.7
(圖 10) Blue	Mean	47.2	35.9	13.6	38.9	32.0
	SD	32.6	21.1	27.6	16.6	13.3

表 2：MRI 影像

		Original	(Ours)	CCADN	BM3D	DIP
(圖 11) Red	Mean	994.4	996.7	1280.4	989	1089.5
	SNR	9.5	15.2	12.8	9.8	18.7

(圖 11) Blue	Mean	1277.0	1278.2	1503.2	1272.2	1433
	SNR	16.3	19.8	21.7	17.8	18.7
(圖 12) Red	Mean	477.3	478.5	627.4	476.1	509.3
	SNR	6.2	10.2	9	6.2	6.9
(圖 12) Blue	Mean	381.9	396.6	495.4	380.3	404.4
	SNR	7.6	14.2	12.3	7.8	11.8

以下比較我們與其他方法在同一張 3D 的電腦斷層上去雜訊所花費的時間，可以得知我們 Training 加上 Test 的時間遠小於其他方法 Test 的時間。

	(Ours)		CCADN	BM3D	DIP
	Train	Test	Test	Test	Test
CT (484 slices)	252.9	73.5	3533	1868	33057 (s)
MRI (360 slices)	222.4	54.7	1294	1188	17028 (s)

八、結論

我們透過利用深度學習的方法，對醫療圖片進行去雜訊，我們的方法與現有的方法最大的差別是，我們去雜訊不需要使用提前訓練好的模型，也就是不受訓練資料的限制，我們可以套用在任何醫學影像上，即便上面有許多未知或不同於以往的雜訊，這也是深度學習最大的優勢。再者，我們最後得出的結果不會遜於其他方法，在大部分的 Case 裡，我們去雜訊的效果更佳，在訓練與測試時間上，我們甚至遠遠低於其他方法，這也是我們的專題所希望的結果。

參考文獻

1. Yujen Chen, Yenjung Chang, and Shaocheng Wen. Zero-shot medical artifact reduction.
2. Yujen Chen, Yenjung Chang, and Shaocheng Wen. "One-Shot" medical image artifact reduction through attentive generative network with internal data synthesis and adversarial training.
3. A. Shocher, N. Cohen, and M. Irani. "Zero-Shot" super-resolution using deep internal learning.
4. Q. Yang, P. Yan, Y. Zhang, H. Yu, Y. Shi, X. Mou, M. K. Kalra, Y. Zhang, L. Sun, and G. Wang. Low dose CT image denoising using a generative adversarial network with Wasserstein distance and perceptual loss.
5. H. Chen, Y. Zhang, M. K. Kalra, F. Lin, Y. Chen, P. Liao, J. Zhou, and G. Wang. Low-dose ct with a residual encoderdecoder convolutional neural network.
6. J. M. Wolterink, T. Leiner, M. A. Viergever, and I. Išgum. Generative adversarial networks for noise reduction in low-dose ct.
7. C. You, Y. Zhang, X. Zhang, G. Li, S. Ju, Z. Zhao, Z. Zhang, W. Cong, P. K. Saha, and G. Wang. Ct super-resolution gan constrained by the identical, residual, and cycle learning ensemble (gan-circle).